

Практическая работа № 4 от 20.03.2020

Вспомогательные библиотеки Python

Цель работы

Изучение некоторых вспомогательных библиотек Python.

Задачи работы

1. Изучить основы библиотеки numpy.
2. Изучить основы библиотеки pandas.
3. Изучить основы библиотеки matplotlib.

Перечень обеспечивающих средств

1. ПК.
2. Учебно-методическая литература.
3. Задания для самостоятельного выполнения.

Общие теоретические сведения

Библиотека numpy

Numpy предоставляет удобный инструментарий для работы с большими, в том числе многомерными, массивами данных.

Основной тип данных (объект) – многомерный массив ndarray (от английского n-dimensional array – n-мерный массив).

Ndarray можно создать напрямую из списка или кортежа с помощью метода `numpy.array()`, например:

```
l = [0, 1, 2]
t = (3, 4, 5)
a1 = numpy.array(l)
a2 = numpy.array(t)
```

Аналогично создается многомерный ndarray:

```
l = [[0, 1, 2], [3, 4, 5], [6, 7, 8]]

a = numpy.array(l)
```

Также есть специальные методы для создания специфических массивов:

`numpy.zeros(t)` – создает массив, заполненный нулями, с размерностями, заданными кортежем `t`. Например, при `t` равном `(3, 3)` будет создан двумерный массив 3 на 3, а при `t` равном `(2, 3, 4)` — трехмерный массив 2 на 3 на 4 и т. п.

Аналогично, метод `numpy.ones(t)` создает массив, заполненный единицами, с размерностями, заданными кортежем `t`.

Метод `numpy.empty(t)` создает пустой массив с размерностями, заданными кортежем `t`.

Также есть метод `numpy.eye(n)`, который создает двумерный квадратный массив `n` на `n` с единичной матрицей, т. е. по диагонали стоят единицы, а в остальных позициях — нули.

Основные свойства массива `ndarray`:

`ndim` — количество измерений или осей массива,

`shape` — кортеж с размерностью массива,

`dtype` — тип элемента в массиве.

С массивами одинаковой размерности можно производить обычные арифметические операции: сложение, умножение и т.д., они выполняются поэлементно.

Также можно выполнять арифметические операции с массивом и числом, при этом операция будет выполняться между каждым элементом массива и числом.

Для получения элементов массива можно использовать индексы и слайсы, аналогично тому, как это делается со списками и кортежами. При этом следующие записи эквивалентны: `a[0][1]`, `a[0, 1]`, `a[(0, 1)]`.

Можно изменить размерность массива с помощью метода `reshape(t)`, где `t` — кортеж, задающий новую форму, например:

```
a = numpy.array([[0, 1], [2, 3], [4, 5]])
```

```
a = a.reshape((2, 3))
```

```
a = a.reshape((6, 1))
```

```
a = a.reshape((1, 6))
```

Библиотека `pandas`

`Pandas` предоставляет инструментарий для работы с табличными данными.

Основные типы данных (объекты): `Series` и `DataFrame`.

`Series` — это одномерный массив с заданным явно или сформированным автоматически индексом. Больше всего он похож на словарь.

```
# Явно заданные индексы
```

```
s1 = pandas.Series({0:1, 2:3, 4:5})
```

```
s2 = pandas.Series([1, 3, 5], index = [0, 2, 4])
```

```
# Автоматические индексы
s3 = pandas.Series([1, 3, 5])
```

DataFrame — это таблица, столбцами которой являются Series. DataFrame можно создать явно, например, из словаря, значениям в котором выступают списки:

```
df = pandas.DataFrame({1 : [1, 2, 3], 2 : [11, 12, 12], 3 : [21, 22, 23]})
```

Другой способ — создать DataFrame из csv-файла, используя метод `read_csv(<Имя файла>, <Разделитель>)`, где разделитель по-умолчанию — запятая.

К отдельным столбцам можно обращаться по их ключам, например, `df[1]`.

К отдельным строкам — с помощью свойства `iloc`, например, `df.iloc[1]`.

Также возможна комбинация индексирования по строкам и столбцам одновременно, в том числе, с применением слайсинга: `df.iloc[1, 1]` или `df.iloc[1, :]`.

В качестве индексов можно указывать условия на значения столбцов, например, `df[df[1] > 1]`.

Добавить новый столбец в DataFrame можно использовать метод `insert(<Номер столбца>, <Имя столбца>, <Значения>)`, где значения могут быть переданы в виде списка. Другой вариант — использовать нотацию словаря. Пример:

```
l = [31, 32, 33]
df.insert(3, 4, l)
df[4] = l
```

Чтобы удалить столбец можно использовать метод `drop(<Имя столбца>)`.

Библиотека matplotlib

Matplotlib предоставляет возможность визуального представления различных данных. Ниже мы рассмотрим основы интерфейса pyplot.

Отображение гистограммы выполняется с помощью метода `matplotlib.pyplot.hist()`, например:

```
x = list(range(100))
matplotlib.pyplot.hist(x)
```

Отображение графика y от x выполняется с помощью метода `matplotlib.pyplot.plot()`, например:

```
x = numpy.array(range(100))
y = x ** 2
```

```
matplotlib.pyplot.plot(x, y)
```

Также `x` и `y` могут быть заданы как имена словаря, `numpy.ndarray`, `pandas.DataFrame` т. п., например:

```
df = pandas.DataFrame({'Икс' : numpy.array(range(100)), 'Игрек' : numpy.array(range(100)) ** 2})  
matplotlib.pyplot.plot('Икс', 'Игрек', data = df)
```

Если передать только один числовой ряд, то он считается значениями `y`, а `x` определяется автоматически.

При необходимости график можно дополнить заголовком, названиями осей, а также ограничить значения, выводимые по обеим осям, следующими методами:

`matplotlib.pyplot.title('<Заголовок>')` - добавляет заголовок,
`matplotlib.pyplot.xlabel('<Ось X>')` - добавляет название оси `X`,
`matplotlib.pyplot.ylabel('<Ось Y>')` - добавляет название оси `Y`,
`matplotlib.pyplot.xlim(min_x, max_x)` – устанавливает значения оси `X` от `min_x` до `max_x`,
`matplotlib.pyplot.ylim(min_y, max_y)` – устанавливает значения оси `Y` от `min_y` до `max_y`,
`matplotlib.pyplot.show()` - отображает график со всеми установленными параметрами.

Пример:

```
df = pandas.DataFrame({'Икс' : numpy.array(range(100)), 'Игрек' : numpy.array(range(100)) ** 2})  
matplotlib.pyplot.plot('Икс', 'Игрек', data = df)  
plt.title('Парабола')  
plt.xlabel('X')  
plt.ylabel('Y')  
plt.xlim(0, 10)  
plt.ylim(0, 10)  
plt.show()
```

Задание

Часть 1

- Сделайте форк репозитория <https://github.com/mosalov/NotebookWithLibs>
- Откройте сайт Binder: <https://mybinder.org/>.
- В поле «GitHub repository name or URL» укажите ссылку на свой репозиторий. Нажмите кнопку «launch», дождитесь открытия репозитория.
- Откройте (кликните) файл «empty_notebook.ipynb».
- Создайте квадратный двумерный массив 4 на 4, заполненный единицами.
- Преобразуйте его в массив, заполненный пятерками.
- Измените форму массива на 2 на 8.
- Выведите получившийся массив.
- Сохраните файл Jupyter notebook с названием «Задание 4_1.ipynb» и загрузите его в созданный репозиторий.

Часть 2

- Вернитесь к файлу «empty_notebook.ipynb», открытому в Binder.
- Создайте пустой DataFrame.
- Добавьте в него столбец «Число» со значениями от 1 до 10.
- Добавьте в него столбец «Квадрат» со значениями, равными квадратам чисел в столбце «Число».
- Создайте новый DataFrame из строк первого DataFrame, в которых значение в столбце «Число» — чётное.
- Удалите из нового DataFrame столбец «Число».
- Выведите получившийся DataFrame.
- Сохраните файл Jupyter notebook с названием «Задание 4_2.ipynb» и загрузите его в созданный репозиторий.

Часть 3

- Вернитесь к файлу «empty_notebook.ipynb», открытому в Binder.
- Создайте DataFrame из файла «winequality-white.csv», обратите внимание на разделитель значений в файле.
- Из полученного DataFrame создайте новый следующим образом:
 - возьмите только те строки, для которых значение в столбце «residual sugar» меньше 1,
 - возьмите только столбцы «density» и «pH»,
 - из результата возьмите только четные строки
- Выведите получившийся DataFrame.
- Сохраните файл Jupyter notebook с названием «Задание 4_3.ipynb» и загрузите его в созданный репозиторий.

Часть 4

- Вернитесь к файлу «empty_notebook.ipynb», открытому в Binder.
- Используя DataFrame, полученный в предыдущем пункте, постройте гистограмму значений в столбце «pH».
- Используя DataFrame, полученный в предыдущем пункте, постройте график для значений в столбце «density».
- Сохраните файл Jupyter notebook с названием «Задание 4_4.ipynb» и загрузите его в созданный репозиторий.

Контрольные вопросы

1. Предложите структуру массива ndarray для хранения состояния кубика Рубика (https://ru.wikipedia.org/wiki/Кубик_Рубика). Приведите пример заполненной структуры для собранного состояния кубика.
2. Постройте график гиперболы $y = 1/x$ на отрезке от -10 до 10.

Требования к отчету

Требуется представить отчет в виде письма на адрес mosalov.op@ut-mo.ru с указанием ФИО и ссылки на репозиторий с сохраненными файлами Jupyter notebook.

Литература

1. <https://pythonworld.ru/numpy/1.html>
2. <https://habr.com/ru/post/352678/>
3. <https://khashtamov.com/ru/pandas-introduction/>
4. <https://habr.com/ru/post/196980/>
5. https://nbviewer.jupyter.org/github/whitehorn/Scientific_graphics_in_python/blob/master/P1%20Chapter%20%20Main%20graphical%20commands.ipynb